

DATA LAKES

TOM & MICHA | ADM SS26

AGENDA

1. **MOTIVATION**
2. **KONZEPTIONELLES MODELL**
3. **DATENSTRUKTUR**
4. **ABFRAGEMODELL**
5. **ARCHITEKTUR**
6. **VERGLEICH ZU RELATIONALEN DATENBANKEN**
7. **DEMO**
8. **AUFGABEN**
9. **ABSCHLUSS**

1. MOTIVATION



PROBLEM-SZENARIO



HISTORIE



BEZUG ZU AI/ML

BEISPIEL: SMART CITY / IOT

VIELE DATENQUELLEN



VERKEHRSSENSOREN
(STREAMS)



WETTERDATEN
(ZEITREIHEN)




LUFTQUALITÄT
(MESSWERTE)



KAMERABILDER
(UNSTRUKTURIERT)



WARTUNGSLOGS
(DOKUMENTE)



PROBLEME



KEINE EINHEITLICHE
STRUKTUR



SCHWIERIGE INTEGRATION
& ANALYSE



UNTERSCHIEDLICHE
DATENQUALITÄT
(RISIKO: DATA SWAMP)



ZIELE



ZENTRALE ABLAGE
ALLER ROHDATEN



DATEN AUFFINDBAR
DURCH METADATEN &
KATALOG



DATEN ANALYSIERBAR
UND NUTZBAR

WARUM EIN DWH HIER SCHEITERT



VERKEHRSSENSOREN
(STREAMS)



WETTERDATEN
(ZEITREIHEN)



LUFTQUALITÄT
(MESSWERTE)




KAMERABILDER
(UNSTRUKTURIERT)



WARTUNGSLOGS
(DOKUMENTE)

ETL-PROZESS
PRO DATENQUELLE



PROBLEME



DATEN PASSEN NICHT IN
VORGEGEBENE
TABELLENSCHEMATA



NEUE DATENQUELLEN
ERFORDERN NEUE ETL
PROZESSE



INFORMATIONSVENLUST -
NUR AGGREGIERTE DATEN

VON DATA WAREHOUSE ZU DATA LAKES (-> LAKEHOUSE)

SEIT ~1990


SEIT ~2010

SEIT ~2020



DATA WAREHOUSE

STRUKTURIERTE DATEN, KONTROLLE




- ✓ STRUKTURIERTE DATEN, FESTES SCHEMA
- ✓ STARKE GOVERNANCE & QUALITÄT
- ✗ UNFLEXIBEL, TEUER BEI NEUEN DATEN
- 🎯 FOKUS: REPORTING & BI



DATA LAKE

ROHDATEN, FLEXIBILITÄT



- ✓ ROHDATEN IN ALLEN FORMATEN SPEICHERN
- ✓ SCHEMA-ON-READ → FLEXIBEL & SKALIERBAR
- ✗ RISIKO: DATA SWAMP OHNE METADATEN
- 🎯 FOKUS: EXPLORATION, DATA SCIENCE, ML



DATA LAKEHOUSE

DAS BESTE AUS BEIDEN WELTEN




- ✓ KOMBINATION: FLEXIBILITÄT + ACID
- ✓ ZIEL: EINE PLATTFORM FÜR BI & ML
- 🎯 FOKUS: BI, STREAMING, ML - ALLES IN EINER PLATTFORM

DATA LAKES ALS GRUNDLAGE FÜR ML & AI

ROHDATEN

DATA LAKE



ML PIPELINE



DATENZUGRIFF



FEATURE
ENGINEERING



MODELL
TRAINING



EVALUATION
DEPLOYMENT


FÜR ML

SPEICHERT DIESE



DATA LAKE = ZENTRALE DATENBASIS FÜR MODERNE ML SYSTEME

2. KONZEPTIONELLES MODELL



WRITE

READ


STRUKTUR

ANALOGIE

SCHEMA-ON-WRITE


SCHEMA WIRD VOR DEM LADEN DER DATEN FESTGELEGT → DATEN MÜSSEN PASSEND TRANSFORMIERT WERDEN BEVOR SIE INS SYSTEM GELANGEN

- STRUKTUR UND VERWENDUNG DER DATEN VORAB DEFINIERT
- **ETL** ALS STANDARDVORGEHEN
- JEDLICHE ARTEN VON TRANSFORMATIONEN VOR DEM SPEICHERN



SCHEMA-ON-READ

- ROHDATEN WERDEN IM ORIGINALFORMAT GESPEICHERT → DIE STRUKTUR WIRD ERST BEIM LESEN/ANALYSIEREN DER DATEN INTERPRETIERT
- SPEICHERUNG IM ORIGINALFORMAT (STRUKTURIERT, UNSTRUKTURIERT, SEMI-STRUKTURIERT)
- KEINE AUFWENDIGE VORVERARBEITUNG
- **ELT** ALS STANDARDVORGEHEN



SCHEMA-ON-WRITE VS. SCHEMA-ON-READ



SCHEMA-ON-WRITE



HOHE QUALITÄT



TEUER & AUFWÄNDIG



KONSISTENZ



UNFLEXIBEL



KLARE SEMANTIK



SCHEMA-ON-READ



HOHE FLEXIBILITÄT



DATA SWAMP



SCHNELLE INGESTION




QUALITÄT UNKLAR



ALLE DATENTYPEN

STRUKTUR/ARCHITEKTUR



PERSONAS IM DATA LAKE

DATA SCIENTISTS & ANALYSTS

- ✓ BAUEN ANALYSE- UND ML-MODELLE
- ✓ NUTZEN LAKE-DATEN FÜR INSIGHTS

ROLLEN IM DATALAKE

GOVERNANCE / RISK/ COMPLIANCE

- ✓ PRÜFE REGELN UND POLICIES
- ✓ AUDIT, ZUGRIFFRECHTE, DATENSCHUTZ

DATA CURATORS

- ✓ DEFINIEREN NEUE DATENQUELLEN
- ✓ PFLEGEN DATEN UND METADATEN


OPERATIONS TEAM

- ✓ BETREIBT UND WARTET PLATTFORM
- ✓ DATENQUALITÄT & INTEGRATION



DIE NUTZER REICHERN DEN LAKE ÜBER ZEIT
MIT QUALITATIVEN DATEN, METADATEN UND
ZUGRIFFSRECHTEN AN

POND ARCHITEKTUR



RAW DATA POND

EINGANG ALLER DATEN, UNVERÄNDERT



ERP, CRM, DBS






DOKUMENTE



VIDEO, BILD

DATEN JE NACH TYP SORTIEREN

TRANSFORMIEREN UND AUFBEREITEN



JEDER DATENTYP LANDET IN SEPARATEM POND

LANGZEIT-SICHERUNG WERTVOLLER DATEN

ZONEN ARCHITEKTUR



LOADING & QUALITY

EINGANG, VALIDIERUNG



RAW

ORIGINALDATEN ARCHIVIERT



CLEANED & VALIDATED

BEREINIGT & STANDARDISIERT



DISCOVERY & EXPLORATION

DATA-SCIENCE-SANDBOX



BUSINESS / RESEARCH

FINALE ANALYSE, BI



LOGIK

JEDER DATENSATZ DURCHLÄUFT DIESE STUFEN

DATEN JE NACH LEBENSZYKLUS SORTIEREN

DATENFLUSS IM DATA LAKE (DATENAUFBEREITUNG)

WARUM SCHRITTWEISE?

- ✓ DATEN ERST BEREINIGEN, VALIDIEREN...
- ✓ DANN DATEN STRUKTURIEREN
- ✓ IM LETZTEN SCHRITT AGGREGIEREN!
SONST IST AGGREGATION EVTL. UNBRAUCHBAR



BRONZE - ROHDATEN (INGESTION)

AUS UNTERSCHIEDLICHEN QUELLEN IM ORIGINALFORMAT

CSV / JSON / LOGS



SILVER - BEREINIGTE DATEN (MAINTENANCE)

BEREINIGT, VALIDIERT, STRUKTURIERT, ANGEREICHERT

DEDUPLIZIERT, KONSISTENT






GOLD - ANALYSEFÄHIGE DATEN (EXPLORATION)

BEREIT FÜR ML & AI, BI, REPORTING





AGGREGIERT, OPTIMIERT

ANALOGIE - DATAWAREHOUSE

- **DWH= STADTBIBLIOTHEK, ALLES SORTIERT IN DEN REGALEN**





ANALOGIE – DATA LAKE




ANALOGIE – DATA SWAMP


- **DATA SWAMP** = DIESELBE LAGERHALLE, ABER OHNE AUFKLEBER



LAKEHOUSE - EINLEITUNG



(a) First-generation platforms.



(b) Current two-tier architectures.


LAKEHOUSE

DREI KERNIDEEN:

1. **OFFENE DATENFORMATE**
 - PARQUET, CSV, JSON, USW.
2. **METADATENLAYER MIT DBMS-FEATURES**
 - ACID-TRANSAKTIONEN
 - BEISPIEL: DELTA LAKE
3. **PERFORMANCE**
 - DIREKTER ZUGRIFF FÜR ML/DATASCIENCE
 - VERGLEICHBARE SQL-PERFORMANCE


EIN SYSTEM STATT ZWEI:

WAREHOUSE-FUNKTIONEN AUF DEM LAKE



(c) Lakehouse platforms.

3.DATENSTRUKTUR



The diagram consists of four identical rectangular blocks arranged horizontally. Each block has a dark green top half and a light green bottom half. The bottom half of each block is slightly offset to the right and down from the top half, creating a layered effect. The text is centered in the light green section of each block.

SPEICHER

FORMATE

PARQUET

METADATEN

Wie Daten physisch gespeichert werden

Data Lake: Objektspeicher als Basis


Eigenschaften



günstig &
skalierbar



immutable
(Append statt Update)



Was bedeutet das?



Daten als Dateien
(Objects)



Kernaussage:

Data Lake = File Storage statt klassische DB

STORAGE TIERS - FILE-BASED SYSTEMS



DATEN WERDEN ALS DATEIEN IM DATEISYSTEM
(Z.B. HDFS) GESPEICHERT

- ✓ EINFACHE UND KOSTENGÜNSTIGE SPEICHERUNG
- ✓ HOHE SKALIERBARKEIT
- ✓ KEINE STRUKTURELLEN EINSCHRÄNKUNGEN (SCHEMA-ON-READ)

TYPISCHE EINSATZSZENARIEN

- ✓ ROHDATENABLAGUNG, GROSSE MENGEN UNSTRUKTURIERTER ODER SEMI-STRUKTURIERTER DATEN

BEISPIELE

HADOOP HDFS

AMAZON S3

STORAGE TIERS - SINGLE DATABASE SYSTEMS



EINE EINZELNE DATENBANK (SQL ODER NOSQL)
SPEICHERT UND VERWALTET ALLE DATEN



ACID TRANSAKTIONEN (BEI RELATIONALEN DBS)



KONSISTENZ UND DATENINTEGRITÄT



SCHEMA-ON-WRITE (RELATIONAL) ODER FLEXIBEL (NOSQL)

TYPISCHE EINSATZSZENARIEN



STRUKTURIERTE DATEN, OPERATIVE ANALYSEN, ANWENDUNGEN MIT HOHEN
KONSISTENZANFORDERUNGEN

BEISPIELE

POSTGRESQL

MONGODB

STORAGE TIERS - POLYSTORE SYSTEMS



**INTEGRIEREN MEHRERE SPEICHER- UND
DATENMODELLE IN EINEM SYSTEM**



UNTERSTÜTZUNG HETEROGENER DATENQUELLEN



FLEXIBLE ABFRAGE ÜBER VERSCHIEDENE STORES



KOMPLEXE ADMINISTRATION

TYPISCHE EINSATZSZENARIEN



VIelfÄLTIGE DATENARTEN UND -MODELLE, KOMBINIerte OLTP/OLAP-
WORKLOADS (SOWOHL VIELE KLEINE TRANSAKTIONEN/GROSSE ANALYSEN)

BEISPIELE

SPARKSQL

SAPHANA

STORAGE TIERS - ON-PREMISE / CLOUD SYSTEMS



DATEN WERDEN IN CLOUD-SPEICHERN ODER
HYBIDEN UMGEBUNGEN ABGELEGT



ELASTISCHE SKALIERBARKEIT



HOHE VERFÜGBARKEIT & AUSFALLSICHERHEIT



PAY-PER-USE (CLOUD)

TYPISCHE EINSATZSZENARIEN



CLOUD NATIVE ANALYSEN, GLOBAL VERTEILTE DATEN, KOSTENEFFIZIENTE
LANGZEITABLAGES

BEISPIELE

AMAZON S3

AZURE DATA LAKE STORAGE

Offene Dateiformate – die wichtigen

Format	Typ	Stärke	Einsatz
 CSV	Text, row	Universal lesbar	Ingest, Austausch
 JSON	Text, semi-structured	Nested Data	Events, Logs
 Avro	Binary, row	Schema-Evolution	Streaming (Kafka)
  Parquet	Binary, columnar	Analytics	Standard im Lake
 ORC	Binary, columnar	Hadoop-Welt	Hive-Ökosystem



Kernaussage:


Parquet = Standardformat für Analytics im Data Lake

Warum Parquet so wichtig ist

Spaltenorientierte Speicherung für Analytics

CSV / Row-based

id	name	price
1	A	10
2	B	20




Um eine Spalte zu lesen,
müssen alle Daten gelesen werden.



Parquet / Columnar

id	name	price
1	A	10
2	B	20



Nur die benötigten Spalten
werden gelesen.



Liest nur benötigte Spalten

Weniger Daten müssen
gelesen werden



Starke Kompression

Höhere Kompression durch
Spaltenorientierung



Schneller für Analytics

Weniger I/O, weniger CPU,
schnellere Queries



Parquet = schneller & effizienter für große Datenanalysen


METADATEN EXTRAKTION IN DATA LAKES



1. ERKENNUNG DES
DATENFORMATS



2. PASSENDER PARSER
WIRD GESTARTET



3. STRUKTUR
EXTRAKTION



4. EIGENSCHAFTEN
EXTRAHIEREN



EXTRAKTION STRUKTURELLER
METADATEN (BÄUME, TABELLEN,
GRAPHEN)



METADATEN-EIGENSCHAFTEN
(Z.B. HEADER, INHALTSHINWEISE)

BEISPIELE

EXTRAKTOR-TOOLS

DATAMARAN (ERKENNT STRUKTUREN IN
LOG-DATEIEN)

SKLUMA (ERKENNT DATEIINFOS (NAME,
TYP, GRÖSSE), ...)

METADATA STORAGE TYPES IN DATA LAKES - GENERIC METADATA MODELS



FLEXIBLE, ALLGEMEINE BESCHREIBUNG VON METADATEN

(METADATEN IN RELATIONALEN TABELLEN SPEICHERN)



SEHR FLEXIBEL UND ERWEITERBAR



GEEIGNET FÜR VIELFÄLTIGE METADATENARTEN



STRUKTURIERT

TYPISCHE EINSATZSZENARIEN



ALLGEMEINE METADATENVERWALTUNG IN DATA LAKES

STRUKTUR

ENTITÄTEN, ATTRIBUTE

BEZIEHUNGEN

METADATA STORAGE TYPES IN DATA LAKES - DATA VAULT MODEL



**STRUKTURIERTE MODELLIERUNG MIT FOKUS AUF
HISTORISIERUNG UND AUDITIERBARKEIT**
["DATA-VAULT-PRINZIP"]



VOLLSTÄNDIGE HISTORISIERUNG



NACHVOLLZIEHBARKEIT VON ÄNDERUNGEN



ERMÖGLICHT GOVERNANCE

TYPISCHE EINSATZSZENARIEN



STRUKTURIERTE DATEN MIT HOHEM BEDARF AN HISTORIE UND AUDIT

ORGANISIERT DATEN MIT

HUB: BUSINESS-KEYS

LINK: BEZIEHUNGEN

SATELITE: ATTRIBUTE+ HISTORIE
(KONTEXT)

METADATA STORAGE TYPES IN DATA LAKES - GRAPH-BASED MODELS



ABBILDUNG VON METADATEN ALS KNOTEN UND KANTEN IN EINEM GRAPHEN

(QUELLEN, TABELLE, ATTRIBUTE ALS KNOTEN / BEZIEHUNGEN ALS KANTEN)



NATÜRLICHE MODELLIERUNG KOMPLEXER BEZIEHUNGEN




HOHE FLEXIBILITÄT UND ERWEITERBARKEIT

TYPISCHE EINSATZSZENARIEN



DATA DISCOVERY IN DATA LAKES



METADATEN ENRICHMENT IN DATA LAKES

SEMANTISCHE METADATEN

- ✓ BEDEUTUNGEN, KONZEPTE UND DOMÄNEN IN DEN DATEN
- ✓ UNTERSTÜTZEN BESSERE EXPLORATION UND DATASET DISCOVERY

WIE?

COREDB: EXTRAKTION VON MERKMALEN (Z.B. KEYWORDS, NAMED ENTITIES), ERWEITERUNG UM SYNONYME, DANN VERKNÜPFUNG MIT WISSENSBASEN (Z.B. GOOGLE KNOWLEDGE GRAPH)

STRUKTURELLE METADATEN

- ✓ STRUKTUREN UND ABHÄNGIGKEITEN, DIE NICHT EXPLIZIT IN DEN DATEN VORLIEGEN
- ✓ UNTERSTÜTZEN DATENBEREINIGUNG UND QUALITÄTBEWERTUNG

WIE?

CONSTANCE: CONSTANCE ENTDECKT „LOSE“ ABHÄNGIGKEITEN, INDEM ES RELAXED FUNCTIONAL DEPENDENCIES AUS DEN DATEN ABLEITET, ALSO REGELN, DIE AUCH DANN GELTEN DÜRFEN, WENN NICHT ALLE TUPEL EXAKT PASSEN ODER ÄHNLICHE WERTE ALS MATCH ZÄHLEN

DESKRIPTIVE METADATEN

- ✓ HERKUNFT, EIGENTÜMER, NUTZUNG UND EIGENSCHAFTEN VON DATASETS
- ✓ UNTERSTÜTZEN ORGANISATION UND DATA GOVERNANCE

WIE?

GOODS: REICHERT METADATEN PER CROWDSOURCING AN, INDEM NUTZER WIE DATA OWNER, AUDITOREN ODER ANDERE TEAMS IM KATALOG BESCHREIBUNGEN ERGÄNZEN ODER SICHERHEITSKRITISCHE DATENSÄTZE MARKIEREN.



METADATA ENRICHMENT VERSUCHT VERSTECKTES WISSEN (IN DEN 3 KATEGORIEN) IN DATEN SICHTBAR ZU MACHEN.

ES IST MEIST ZEITAUFWÄNDIG UND WIRD ERST NACH DER INGESTION DURCHFÜHRT, LIEFERT ABER ESSENZIELLE INFORMATIONEN FÜR VIELE FUNKTIONEN IM DATA LAKE!

4.ABFRAGEMODELL

DUCKDB SQL

**UNTERSCHIEDE ZUM
KLASSISCHEN SQL**


DELTA LAKE

APACHE SPARK

DUCKDB – WAS BRINGT DAS EIGENTLICH?



DUCKDB – WAS BRINGT DAS EIGENTLICH?



DUCKDB – WAS BRINGT DAS EIGENTLICH?

STANDARD-SQL-WEG

```
-- 1. AWS CLI: 12 CSV-Files runterladen
$ aws s3 cp s3://bucket/sales/2024_01.csv ./
$ aws s3 cp s3://bucket/sales/2024_02.csv ./
$ ... [10 weitere cp Befehle]

-- 2. 12x COPY in Postgres
COPY sales_2024_01 FROM '2024_01.csv' WITH (FORMAT csv);
COPY sales_2024_02 FROM '2024_02.csv' WITH (FORMAT csv);
... [10 weitere COPY Statements]

-- 3. UNION ALL über 12 Tabellen
SELECT region, SUM(revenue) FROM (
  SELECT * FROM sales_2024_01 UNION ALL
  SELECT * FROM sales_2024_02 UNION ALL
  ... [10 weitere UNION ALL]
) GROUP BY region;
```

DUCK-DB-WEG

```
SELECT region, SUM(revenue)
FROM 's3://bucket/sales/2024_*.csv'
GROUP BY region;
```

DUCKDB – ALLGEMEINE INFORMATIONEN

WAS IST DUCKDB?



- EMBEDDED ANALYTISCHE DATENBANK
- IN-PROCESS (KEIN SERVER)
- OPEN-SOURCE

TECHNIK



- SPALTENORIENTIERT (OLAP)
- ACID-TRANSAKTIONEN
- ZERO SETUP

WANN NUTZEN?



- LOKALE DATEN ANALYSE
- NOTEBOOK-WORKFLOWS
- LERNZWECKE

WANN NICHT NUTZEN?



- VERTEILTE WORKLOADS
- OLTP
- MULTI-USER SERVER-DB

LIEST DIREKT AUS:

EXCEL

MYSQL

POSTGRESQL

AWS S3

TEXT FILES

JSON

CSV

PARQUET

DELTA LAKE

AZURE BLOB STORAGE

DUCKDB – GRUNDLAGEN

```
-- Zugriff direkt auf Datei
SELECT * FROM 'flights.datenFormat';

-- Zugriff über Funktion read_()
SELECT * FROM read_datenFormat('flights.datenFormat');

-- Mehrere Datenobjekte über Glob-Pattern (Muster)
SELECT * FROM 'dir/flights*.datenFormat';

-- Mehrere Datenobjekte über read_() mit Glob-Pattern
SELECT * FROM read_datenFormat('dir/flights*.datenFormat');

-- Mehrere Dateien explizit als Liste (genaue Auswahl)
SELECT * FROM read_datenFormat(['flights1.datenFormat', 'flights2.datenFormat', 'flights3.datenFormat']);

-- Schemata kombinieren: Spalten nach Namen zusammenführen (fehlende = NULL)
SELECT * FROM read_csv(['flights3.csv', 'flights4.csv'], union_by_name = true);

-- Tabelle aus Datei erzeugen (Daten werden importiert)
CREATE TABLE flights AS
  SELECT * FROM 'flights.datenFormat';

-- Export: Ergebnis in Datei schreiben
COPY (SELECT * FROM flights WHERE jahr = 2024)
  TO 'flights_2024.datenFormat';
```

WEITERE QUERY ENGINES – APACHE SPARK

DUCK DB GRENZEN

- NUR SINGLE-NODE EINE MASCHINE
- RAM & CPU LIMIT
- KEIN ML-FRAMEWORK
- KEIN STREAMING
- NICHT FÜR MULTI-USER

APACHE SPARK

- DISTRIBUTED COMPUTING: CLUSTER MIT NODES
- PETABYTE-SCALE
- MLLIB INTEGRIERT
- STRUCTURED STREAMING
- CLUSTER FÜR TEAMS

→ DUCKDB: LOKAL & SCHNELL
→ SPARK: GROß VERTEILT
BEIDE ERGÄNZEN SICH

DELTA LAKE

WAS IST DELTA LAKE?

- OPEN SOURCE STORAGE LAYER
- LIEGT AUF PARQUET
- FÜGT EIN **TRANSACTION-LOG** HINZU


KERN FEATURES:

- ACID-TRANSAKTIONEN
- TIME TRAVEL
- SCHEMA ENFORCEMENT



```
{
  "commitInfo": {
    "timestamp": 1777886706892,
    "operation": "WRITE",
    "engineInfo": "delta-rs:py-1.5.1",
    "operationMetrics": {
      "num_added_files": 1,
      "num_added_rows": 360
    }
  },
  "metaData": {
    "id": "f6674968-e02e-...",
    "format": { "provider": "parquet" },
    "schemaString": "{flight_id, source, dest, passenger, datum}"
  },
  "add": {
    "path": "part-00000-...parquet",
    "size": 6969,
    "stats": {
      "numRecords": 360,
      "minValues": {
        "source": "BER",
        "datum": "2025-01-01"
      },
      "maxValues": {
        "source": "STR",
        "datum": "2025-03-31"
      }
    }
  }
}
```

5.ARCHITECTURE



**COMPUTE-
STORAGE-
SEPARATION**

**INGESTION-
PIPELINES**


**CLOUD-LANDSCAPE
TABELLE**

DATA GOVERNANCE

TRENNUNG VON STORAGE UND COMPUTE

WARUM DIESE TRENNUNG?

- ✓ STORAGE = BILLIG / COMPUTE = TEUER
- ✓ COMPUTE NUR TEMPORÄR, BEI BEDARF ABRUFEN (UND DAS SKALIERBAR)
- ✓ SEPARATE ENTWICKLUNG & WARTUNG



TYPISCHE INGESTION PIPELINES IN DATA LAKES

BATCH


DATEN WERDEN IN FESTEN ZEITABSTÄNDEN GESAMMELT UND GESAMMELT (Z. B. PER CRON-JOB) ALS KOMPLETTE PAKETE IN DEN DATA LAKE GELADEN.



CRON



SCRIPT



DATA LAKE

STREAMING


DATEN WERDEN KONTINUIERLICH IN ECHTZEIT VERARBEITET UND DIREKT WÄHREND IHRES ENTSTEHENS IN DEN DATA LAKE GESCHRIEBEN.



KAFKA
(LIEFERT DATEN)



SPARK STREAMING
(VERARBEITET IN ECHTZEIT)




DATA LAKE

CDC (CHANGE DATA CAPTURE)

CDC FUNKTIONIERT, INDEM NUR ÄNDERUNGEN (INSERT, UPDATE, DELETE) AUS EINER QUELLE KONTINUIERLICH ERKANNT UND DIREKT IN DEN DATA LAKE ÜBERTRAGEN WERDEN, STATT DIE GESAMTEN DATEN NEU ZU LADEN.



DEBEZIUM
(LIEST ÄNDERUNGSLOGS)



DATA LAKE

CLOUD LANDSCAPE IN DATA LAKES



AMAZON WEB SERVICES

- ✓ AMAZON S3 / S3 GLACIER (STORAGE)
- ✓ AWS GLUE (ETL/ELT & DATA CATALOG)
- ✓ AMAZON ATHENA (QUERY)
- ✓ AMAZON EMR (PROCESSING)
- ✓ AMAZON QUICKSIGHT (BI & ANALYTICS)
- ✓ AWS LAKE FORMATION (GOVERNANCE)



MICROSOFT AZURE

- ✓ AZURE DATA LAKE STORAGE GEN2 (STORAGE)
- ✓ AZURE DATA FACTORY (ETL/ELT)
- ✓ AZURE DATABRICKS (PROCESSING)
- ✓ AZURE SYNAPSE ANALYTICS (ANALYTICS)
- ✓ AZURE PURVIEW (GOVERNANCE & CATALOG)
- ✓ AZURE ACTIVE DIRECTORY (SECURITY)



GOOGLE CLOUD PLATFORM

- ✓ GOOGLE CLOUD STORAGE (STORAGE)
- ✓ DATAFLOW / DATAPROC (PROCESSING)
- ✓ BIGQUERY (ANALYTICS)
- ✓ DATA CATALOG (METADATA)
- ✓ CLOUD COMPOSER (ORCHESTRATION)
- ✓ IAM (SECURITY & ACCESS)

KLASSISCHE CLOUD VORTEILE

- ✓ ELASTISCHE SKALIERBARKEIT
- ✓ HOHE VERFÜGBARKEIT
- ✓ SCHNELLE BEREITSTELLUNG
- ✓ PAY-PER-USE

DATA GOVERNANCE IM DATA LAKE



METADATA MANAGEMENT

- Struktur-, semantische und beschreibende Metadaten
- Datenherkunft (Lineage) und Zusammenhänge
- Grundlage für Auffindbarkeit und Verständnis



DATA QUALITY & PROVENANCE

- Herkunft und Nachvollziehbarkeit von Daten
- Qualitätssicherung und Datenbereinigung
- Nachvollziehbarkeit von Änderungen



ACCESS CONTROL & SECURITY

- Rollenbasierte Zugriffsrechte und Autorisierung
- Authentifizierung und Verschlüsselung
- Einhaltung von Governance- und Compliance-Anforderungen



DATA CATALOG & ORGANISATION

- Zentrale Metadatenhaltung und Datenkatalog
- Suche, Discovery und Datenexploration
- Strukturierung und Klassifizierung von Daten

FRAGEN

- WELCHE INGESTION-ART WÜRDET IHR FÜR SENSORDATEN EINER SMART CITY WÄHLEN: BATCH, STREAMING ODER CDC? WARUM?

VERGLEICH RDBMS VS. DATA LAKE VS. LAKEHOUSE

**DIREKTER
VERGLEICH**

**WANN WELCHE
ARCHITEKTUR
GLÄNZT**

**WAS DATA LAKES
NICHT GUT KÖNNEN**

VERGLEICH – RDBMS VS. DATA LAKE VS. LAKEHOUSE

ASPEKT	RDBMS	DATA LAKE	LAKEHOUSE
 Schema	On-Write Schema beim Schreiben definiert und strikt eingehalten	On-Read Schema erst beim Lesen angewendet (Schema flexibel)	Beides möglich Schema-Enforcement möglich, aber evolvierbar
 Datentypen	Strukturiert Relationale Tabellen, feste Typen	Alle Strukturiert, semi-strukturiert, unstrukturiert (z. B. Bilder, Videos, Logs)	Strukturiert + semi Strukturierte Daten mit Support für semi-strukturierte Daten
 ACID	 Vollständig unterstützt	 Nicht vorhanden	 Vollständig unterstützt
 Skalierung	Vertikal Hochskalierung (Scale-Up)	Horizontal Ausbau über viele günstige Knoten (Scale-Out)	Horizontal Ausbau über viele Knoten (Scale-Out)
 Kosten	€ € € Höhere Kosten	€ Geringe Kosten	€ € Mittlere Kosten
 Hauptnutzen	OLTP, BI Transaktionen, Reporting, Business Intelligence	ML, Exploration Rohdaten für Machine Learning, Explorative Analysen	BI, ML Business Intelligence und Machine Learning kombiniert
 Governance	Stark Etablierte Mechanismen (z. B. Rollen, Rechte, Constraints)	Schwach Ohne zusätzliche Maßnahmen (Risiko: Data Swamp)	Stark Governance durch ACID, Schema, Kataloge, Audit-Logs



Fazit: RDBMS für transaktionale Workloads, Data Lake für Rohdaten & ML, Lakehouse vereint die Vorteile beider Welten.

WANN WELCHE ARCHITEKTUR GLÄNZT



BANKENSYSTEM
TRANSAKTIONEN

RDBMS GLÄNZT

- ✓ STARKE KONSISTENZ (ACID)
- ✓ STRUKTURIERT & SCHEMAFEST



SMART CITY / IOT
SENSOREN, LOGS ...

DATA LAKE GLÄNZT

- ✓ ALLE DATENTYPEN
- ✓ SCHEMA-ON-READ



ANALYTICS
BI + MACHINE LEARNING

LAKEHOUSE GLÄNZT

- ✓ ACID + SCHEMA + GOVERNANCE
- ✓ UNTERSÜTZT BI + ML

WAS DATA LAKES NICHT GUT KÖNNEN (DIE 3 SCHWÄCHEN)



TRANSAKTIONSKONSISTENZ & ACID



SCHEMA & DATENTYPENDURCHSETZUNG



ZUGRIFFSRECHTE & DATENGOVERNANCE

7. DEMO



8. AUFGABEN

QUELLEN

- [HTTPS://WWW.RESEARCHGATE.NET/FIGURE/OVERVIEW-OF-THE-THREE-LAYERED-INFORMATION-STORAGE-MODEL-CONTAINING-THE-RAW-DATA-AT-THE_ FIG6_ 327566909](https://www.researchgate.net/figure/overview-of-the-three-layered-information-storage-model-containing-the-raw-data-at-the_fig6_327566909)
- [HTTPS://AZURE.MICROSOFT.COM/DE-DE/RESOURCES/CLOUD-COMPUTING-DICTIONARY/WHAT-IS-A-DATA-LAKE](https://azure.microsoft.com/de-de/resources/cloud-computing-dictionary/what-is-a-data-lake)
- [HTTPS://WWW.DATABRICKS.COM/BLOG/WHAT-IS-DATA-LAKEHOUSE](https://www.databricks.com/blog/what-is-data-lakehouse)
- [HTTPS://WWW.DATABRICKS.COM/DE/DISCOVER/DATA-LAKES](https://www.databricks.com/de/discover/data-lakes)
- [HTTPS://WWW.DATABRICKS.COM/DISCOVER/DATA-LAKES/CHALLENGES](https://www.databricks.com/discover/data-lakes/challenges)
- KI GENERIERTE FOLIEN: FOLIEN 22, 27, 28, 46, 49

PAPERS:

- [HTTPS://ARXIV.ORG/ABS/2108.09020](https://arxiv.org/abs/2108.09020)
- [HTTPS://ARXIV.ORG/ABS/1908.00925](https://arxiv.org/abs/1908.00925)